Министерство науки и высшего образования Российской Федерации Федеральное государственное автономное образовательное учреждение высшего образования «СЕВЕРО-КАВКАЗСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»

Институт перспективной инженерии Департамент цифровых, робототехнических систем и электроники

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №5 дисциплины

«Искусственный интеллект и машинное обучение» Вариант-3

	Выполнил: Пугачев Кирилл Дмитриевич 2 курс, группа ИТС-б-о-23-1, 11.03.02 Инфокоммуникационные технологии и системы связи, очная форма обучения
	(подпись) Проверила: Ассистент департамента цифровых, робототехнических систем и электроники Хацукова А.И
	(подпись)
Отчет защищен с оценкой	Дата защиты

Tema: ВВЕДЕНИЕ В PANDAS: ИЗУЧЕНИЕ СТРУКТУРЫ SERIES И БАЗОВЫХ ОПЕРАЦИЙ

Цель работы: познакомить с основами работы с библиотекой pandas, в частности, со структурой данных DataFrame.

Ссылка на репозиторий: https://github.com/chillkirill/LABA5AI Ход работы:

1. Выполнение практических заданий.

Рисунок 1. Установка окружения

Рисунок 2. Установка библиотек

```
🕄 Администратор: Anaconda Prompt - conda activate myenv - conda install ipykernel
                       pkgs/main/win-64::six-1.17.0-py312haa95532_0
pkgs/main/noarch::stack_data-0.2.0-pyhd3eb1b0_0
  stack_data
                       pkgs/main/win-64::tornado-6.5-py312h827c3e9_0
  tornado
                      pkgs/main/win-64::traitlets-5.14.3-py312haa95532_0
  traitlets
                       pkgs/main/noarch::wcwidth-0.2.5-pyhd3eb1b0 0
  wcwidth
                       pkgs/main/win-64::zeromq-4.3.5-hd77b12b_0
  zeromq
Proceed ([y]/n)? python -m ipykernel install --user --name=myenv --display-name="Python (myenv)"
Invalid choice: python -m ipykernel install --user --name=myenv --display-name="python (myenv)
Proceed ([y]/n)? y
Downloading and Extracting Packages:
Preparing transaction: done
Verifying transaction: done
Executing transaction: done
(myenv) C:\Users\user>_
```

Рисунок 3. Активация myenv

```
Python (myenv)
Python 3 (ipykernel)
```

Рисунок 4. Результат

```
(myenv) C:\Users\user>conda install -c conda-forge black
Channels:
- conda-forge

    defaults

Platform: win-64
Collecting package metadata (repodata.json): done
Solving environment: done
## Package Plan ##
 environment location: E:\Anaconda\envs\myenv
  added / updated specs:
    - black
The following packages will be downloaded:
                                             build
    package
    black-25.1.0
                                                           169 KB conda-forge
                                      pyh866005b_0
    ca-certificates-2025.4.26
                                        h4c7d964 0
                                                           149 KB
                                                                   conda-forge
```

Рисунок 5. Установка утилиты black

```
PS E:\Anaconda\Scripts\11aba\5 laba> isort . --check-only
Skipped 2 files
PS E:\Anaconda\Scripts\1laba\5 laba> black .
  ipping ip n i p p n n i n
        left unchanged.
PS E:\Anaconda\Scripts\1laba\5 laba> isort .
Skipped 2 files
PS E:\Anaconda\Scripts\1laba\5 laba> flake8
  ipynb_checkpoints\1ind-checkpoint.py:5:23: F821 undefined name 'null'
 \.ipynb_checkpoints\lind-checkpoint.py:14:89: E501 line too long (91 > 88 characters)
 \.ipynb_checkpoints\1ind-checkpoint.py:32:89: E501 line too long (101 > 88 characters)
        checkpoints\lind-checkpoint.py:52:89: E501 line too long (121 > 88 characters)
         checkpoints\lind-checkpoint.py:61:89: E501 line too long (101 > 88 characters)
         checkpoints\lind-checkpoint.py:65:89: E501 line too long (102 > 88 characters)
   ipynb_checkpoints\1ind-checkpoint.py:72:23: F821 undefined name 'null'
        checkpoints\1pr-checkpoint.py:66:89: E501 line too long (91 > 88 characters)
        checkpoints\1pr-checkpoint.py:75:89: E501 line too long (129 > 88 characters)
        checkpoints\ipr-checkpoint.py:76:89: E501 line too long (138 > 88 characters)
        checkpoints\ipr-checkpoint.py:77:89: E501 line too long (139 > 88 characters)
        _checkpoints\1pr-checkpoint.py:78:89: E501 line too long (134 > 88 characters)
         checkpoints\ipr-checkpoint.py:79:89: E501 line too long (133 > 88 characters)
         checkpoints\1pr-checkpoint.py:101:23: F821 undefined name 'null'
         theckpoints\2.1pr-checkpoint.py:64:89: E501 line too long (91 > 88 characters)
   ipynb_checkpoints\2.1pr-checkpoint.py:65:89: E501 line too long (114 > 88 characters)
         checkpoints\2.1pr-checkpoint.py:66:89: E501 line too long (126 > 88 characters)
         checkpoints\2.1pr-checkpoint.py:67:89: E501 line too long (105 > 88 characters)
         checkpoints\2.1pr-checkpoint.py:68:89: E501 line too long (146 > 88 characters)
         checkpoints\2.1pr-checkpoint.py:69:89: E501 line too long (169 > 88 characters)
         checkpoints\2.1pr-checkpoint.py:70:89: E501 line too long (235 > 88 characters)
         heckpoints\2.1pr-checkpoint.py:71:89: E501 line too long (169 > 88 characters)
         checkpoints\2.1pr-checkpoint.py:72:89: E501 line too long (96 > 88 characters)
         checkpoints\2.1pr-checkpoint.py:89:23: F821 undefined name 'null'
         checkpoints\2.2pr-checkpoint.py:42:89: E501 line too long (91 > 88 characters)
               pints\2.2pr-checkpoint.py:43:89: E501 line too long (114 > 88 characters)
         checkpoints\2.2pr-checkpoint.py:44:89: E501 line too long (126 > 88 characters)
                 mts\2.2pr-checkpoint.py:45:89: E501 line too long (105 > 88 characters)
          heckpoints\2.2pr-checkpoint.py:46:89: E501 line too long (154 > 88 characters)
   pynb_checkpoints\2.2pr-checkpoint.py:47:89: E501 line too long (128 > 88 characters)
         checkpoints\2.2pr-checkpoint.py:48:89: E501 line too long (109 > 88 characters)
         checkpoints\2.2pr-checkpoint.py:49:89: E501 line too long (112 > 88 characters)
         checkpoints\2.2pr-checkpoint.py:50:89: E501 line too long (143 > 88 characters)
         checkpoints\2.2pr-checkpoint.py:51:89: E501 line too long (144 > 88 characters)
  ipynb_checkpoints\2.2pr-checkpoint.py:69:23: F821 undefined name 'null'
  ipynb_checkpoints\2.3pr-checkpoint.py:26:89: E501 line too long (91 > 88 characters)
\.ipynb_checkpoints\2.3pr-checkpoint.py:27:89: E501 line too long (114 > 88 characters)
```

Рисунок 6. Результат утилитов

Рисунок 7. Создание конфигурационного файла

Рисунок 8. Создание конфигурационного файла.

```
import pandas as pd
import numpy as np
# DataFrame из словаря списков
data dict = {
   'ID': [1, 2, 3, 4, 5],
   'Имя': ['Иван', 'Ольга', 'Алексей', 'Мария', 'Сергей'],
   'Возраст': [25, 30, 40, 35, 28],
   'Должность': ['Инженер', 'Аналитик', 'Менеджер', 'Программист', 'Специалист'], 'Отдел': ['ИТ', 'Маркетинг', 'Продажи', 'ИТ', 'HR'], 'Зарплата': [60000, 75000, 90000, 80000, 50000],
   'Стаж работы': [2, 5, 15, 7, 3]
df_from_dict = pd.DataFrame(data_dict)
# DataFrame из списка словарей
list_of_dicts =
   df_from_list_of_dicts = pd.DataFrame(list_of_dicts)
# DataFrame из массива NumPy со случайными числами (от 20 до 60) для возраста
np.random.seed(0)
random_ages = np.random.randint(20, 61, size=5)
df_from_np = pd.DataFrame({'Bospact': random_ages})
# Проверка типов данных с помощью .info()
print("DataFrame из словаря списков:")
df_from_dict.info()
print("\nDataFrame из списка словарей:")
df_from_list_of_dicts.info()
print("\nDataFrame из массива NumPy:")
df_from_np.info()
```

Рисунок 9. Практическое задание 1

```
DataFrame из словаря списков:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 7 columns):
               Non-Null Count Dtype
# Column
                   -----
0 ID 5 non-null int64
1 Имя 5 non-null object
2 Возраст 5 non-null int64
3 Должность 5 non-null object
4 Отдел 5 non-null object
5 Зарплата 5 non-null int64
                                     object
                                     object
                                     object
 6 Стаж работы 5 non-null
                                     int64
dtypes: int64(4), object(3)
memory usage: 412.0+ bytes
DataFrame из списка словарей:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 7 columns):
# Column Non-Null Count Dtype
---
                   -----
0 ID 5 non-null
1 Имя 5 non-null
2 Возраст 5 non-null
3 Должность 5 non-null
4 Отдел 5 non-null
5 Зарплата 5 non-null
                                     int64
                                     object
                                    object
                                     int64
6 Стаж работы 5 non-null
                                    int64
dtypes: int64(4), object(3)
memory usage: 412.0+ bytes
DataFrame из массива NumPy:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 1 columns):
# Column Non-Null Count Dtype
0 Возраст 5 non-null int32
dtypes: int32(1)
memory usage: 152.0 bytes
```

Рисунок 10. Результат первого задания

Рисунок 11. Практическое задание 2.1

```
import pandas as pd
data clients =
      df_clients = pd.DataFrame(data_clients)
# DataFrame & Excet-фaŭn
excel_filename = 'tab2.xisx'
sheet_name = 'Knmetru'
df_clients.to_excel(excel_filename, sheet_name=sheet_name, index=False)
# ma6лица из файла обратно в DataFrame
loaded_df = pd.read_excel(excel_filename, sheet_name=sheet_name)
print(loaded df)
                                                                  Город Баланс на счете Кредитная история
Москва 120000 Хорошая
гербург 80000 Средняя
                                                                                                               Хорошая
Хорошая
Средняя
Плохая
                 Иван
Ольга
                                  34 Москва
27 Санкт-Петербург
                                27 Санкт-Петербург
45 Казань
38 Новосибирск
29 Екатеринбург
50 Воронеж
31 Челябинск
40 Краснодар
28 Ростов-на-Дону
33 Уфа
46 Омск
37 Пермен
41 Томены
25 Саратов
39 Самара
42 Волгоград
49 Барнаул
50 Иркутск
30 Хабаровск
35 Томск

    3 Алексей
    4 Мария

                                                                                                150000
              Мария
Сергей
Анна
                                                                                                                           Хорошая
                                                                                 200000
95000
300000
140000
175000
110000
                                                                                               200000
95000
                                                                                                                           Средняя
Отличная
     6 Анна
7 Дмитрий
8 Елена
9 Виктор
10 Алиса
11 Павел
12 Светлана
13 Роман
14 Татъван
15 Николай
16 Валерия
17 Григория
18 Юлия
19 Степан
                                                                                                                          Отличная
Средняя
Хорошая
Плохая
Средняя
Средняя
Отличная
Средняя
Хорошая
                                                                                               175000
110000
98000
250000
210000
135000
125000
180000
275000
                                                                                                                             Хорошая
Средняя
Плохая
                                                                                                                           Отличная
                                                                                                 275000
320000
                                                                                                  105000
19 20 Василиса
```

Рисунок 12. Практическое задание 2.2

```
### By Boyact | Appendix | Section | Appendix | Appendi
```

Рисунок 13. Практическое задание 2.3

```
[2]: import pandas as pd
      # DataFrame из таблиць
         df = pd.DataFrame(data)
     print("Информация о сотруднике с ID=5:\n", info_ID_5)
             аст третьего сотрудника в таблице с помощью .iloc[]
      age_third_employee = df.iloc[2]['Boзpact']
print("\nBoзpact третьего сотрудника:", age_third_employee)
     # название отдела для сотрудника "Мария" с помощью .at[]
department_maria = df.at[df.index[df['Имя'] == 'Мария'][0], 'Отдел']
     print("\nОтдел сотрудницы 'Мария':", department_maria)
      salary_value = df.iat[3, 4]
print("\nЗарплата сотрудника из 4-й строки и 5-го столбца:", salary_value)
     Информация о сотруднике с ID=5:
Имя Сергей
      Возраст
Должность
                  Специалист
      Отдел HR
Зарплата 50000
      Стаж работы
Name: 5, dtype: object
     Возраст третьего сотрудника: 40
     Отдел сотрудницы 'Мария': ИТ
     Зарплата сотрудника из 4-й строки и 5-го столбца: 80000
```

Рисунок 14. Практическое задание 3

Рисунок 15. Практическое задание 4

```
### Distriction of the Control of th
```

Рисунок 16. Практическое задание 5

Рисунок 17. Практическое задание 6

```
import pandas as pd
  # DataFrame из таблиць
                 'ID': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20],
               'Ш': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20],
'Имя: ('Имя-', 'Ольга', 'Алексей, 'Мария', 'Сергей', 'Анна', 'Дмигрий', 'Елена', 'Виктор', 'Алиса',
'Павел', 'Светлана', 'Роман', 'Татьяна', 'Николай', 'Валерия', 'Григорий', 'Юлия', 'Степан', 'Василиса'],
'Возраст': [34, 27, 45, 38, 29, 50, 31, 40, 28, 33, 46, 37, 41, 25, 39, 42, 50, 50, 30, 35],
'Город': ['Москва', 'Санкт-Петербург', 'Казань', 'Новосибирск', 'Екатеринбург', 'Вельорнек', 'Чельбинск', 'Краснодар', 'Ростов-на-Дону', 'Уфа',
'Омск', 'Пермы', 'Томень', 'Саратов', 'Самара', 'Волгоград', 'Барнаул', 'Иркутск', 'Хабаровск', 'Томск'],
'Валанс на счете': [120000, 80000, 150000, 200000, 95000, 300000, 140000, 175000, 110000, 98000,
                250000, 21000, 135000, 155000, 125000, 180000, 275000, 320000, 105000, 90000],

'Кредитная история': ['Хорошая', 'Средняя', 'Плохая', 'Хорошая', 'Средняя', 'Отличная', 'Средняя', 'Хорошая', 'Средняя', 'Плохая', 'Средняя', 'Средн
 df = pd.DataFrame(data)
# количество непустых значений non_empty_counts = df.count()
                                                                          их значений в каждом столбце (.count())
 print("Количество непустых значений в каждом столбце:")
 print(non_empty_counts)
             частота встречаемости значений в "Город" (.value_counts())
city_counts = df['Город'].value_counts()
print("\nЧастота встречаемости значений в 'Город':")
 print(city_counts)
           количество уникальных значений в "Город", "Возраст" и "Баланс на счете" (.nunique())
                 ue_counts = {
'Город': df['Город'].nunique(),
                'Bospact': df['Bospact'].nunique(),
'Баланс на счете': df['Баланс на счете'].nunique()
 print("\nКоличество уникальных значений:")
 for key, value in unique_counts.items():
    print(f"{key}: {value}")
 Количество непустых значений в каждом столбце:
 Возраст
 Город
Баланс на счете
Кредитная история
 dtype: int64
 Частота встречаемости значений в 'Город':
 Город
```

Рисунок 18. Практическое задание 7

Рисунок 19. Практическое задание 8

3. Использовать DataFrame, содержащий следующие колонки: фамилия и инициалы; номер группы; успеваемость (дополнительные колонки по предметам). Написать программу, выполняющую следующие действия: ввод с клавиатуры данных и добавление строк в DataFrame; записи должны быть упорядочены по алфавиту; вывод на дисплей фамилий и номеров групп для всех студентов, имеющих хотя бы одну оценку 2; если таких студентов нет, вывести соответствующее сообщение.

Рисунок 20. Задание к 3 варианту

Рисунок 21. Индивидуально задание 1

Ответы на контрольные вопросы:

1. Как создать pandas.DataFrame из словаря списков?

Можно передать словарь, где ключи — названия столбцов, а значения — списки данных. pandas автоматически создаст таблицу по этим данным.

2. В чем отличие создания DataFrame из списка словарей и словаря списков?

Отличия:

- Список словарей: лучше, когда у данных разные наборы ключей, и некоторые строки могут иметь пропуски.
- Словарь списков: удобно, когда все столбцы и строки есть заранее, и структура однородна.
 - 3. Как создать pandas.DataFrame из массива NumPy?

Можно передать массив NumPy, указав имена столбцов через columns.

4. Как загрузить DataFrame из CSV-файла, указав разделитель ; ?

df = pd.read_csv('файл.csv', delimiter=';')

5. Как загрузить данные из Excel в pandas.DataFrame и выбрать конкретный лист?

df = pd.read_excel('файл.xlsx', sheet_name='Лист1')

- 6. Чем отличается чтение данных из JSON и Parquet в pandas?
- JSON: читается функцией pd.read_json(). Формат текстовый, удобен для обмена данными.
- Parquet: читается pd.read_parquet(). Это бинарный формат, более эффективный для больших данных и поддерживает схему.
 - 7. Как проверить типы данных в DataFrame после загрузки? print(df.dtypes)
- 8. Как определить размер DataFrame (количество строк и столбцов)?

rows, cols = df.shape

- 9. В чем разница между .loc[] и .iloc[]?
- .loc[] использует метки индексов (имена строк),
- .iloc[] использует целочисленные позиции (индексы по порядку).
- 10. Как получить данные третьей строки и второго столбца с .iloc[]?

value = df.iloc[2, 1]

11. Как получить строку с индексом "Мария" из DataFrame?

row = df.loc['Мария']

12. Чем .at[] отличается от .loc[] ?

- .at[] быстрый доступ к одному элементу по метке (строка и столбец).
- .loc[] для доступа к диапазонам или множественным значениям.

13. В каких случаях .iat[] работает быстрее, чем .iloc[]?

- .iat[] для получения одного элемента по позиций, быстрее при одиночных обращениях.
 - .iloc[] для срезов и более сложных операций.
- 14. Как выбрать все строки, где "Город" равен "Москва" или "СПб", используя.isin()?

 $df_filtered = df[df['Город'].isin(['Москва', 'СПб'])]$

15. Как отфильтровать DataFrame, оставив только строки, где "Возраст" от 25 до 35 лет, используя .between()?

df_filtered = df[df['Bo3pact'].between(25, 35)]

- 16. В чем разница между .query() и .loc[] для фильтрации данных?
- .query() принимает строку с условием, что позволяет писать компактные выражения.
 - .loc[] использует Python-выражения, обращение по именам столбцов.
 - 17. Как использовать переменные Python внутри .query()?

 $min_age = 25$

df.query('Возраст >= @min_age')

18. Как узнать, сколько пропущенных значений в каждом столбце DataFrame ?

df.isna().sum()

- 19. В чем разница между .isna() и .notna()?
- .isna() возвращает True для пропущенных значений.
- .notna() возвращает True для непустых значений.
- **20.** Как вывести только строки, где нет пропущенных значений? df_clean = df.dropna()

21. Как добавить новый столбец "Категория" в DataFrame , заполнив его фиксированным значением "Неизвестно" ?

df['Категория'] = 'Неизвестно'

22. Как добавить новую строку в DataFrame, используя .loc[]?

new_index = 'Новая'

df.loc[new_index] = ['Иван', 28, 'Москва', 'Неизвестно']

23. Как удалить столбец "Возраст" из DataFrame?

df = df.drop('Возраст', axis=1)

24. Как удалить все строки, содержащие хотя бы один NaN, из DataFrame?

df_clean = df.dropna()

25. Как удалить столбцы, содержащие хотя бы один NaN , из DataFrame ?

df_clean = df.dropna(axis=1)

26. Как посчитать количество непустых значений в каждом столбие DataFrame ?

df.count()

- 27. Чем .value_counts() отличается от .nunique()?
- .value_counts() считает количество каждого уникального значения в столбце.
 - .nunique() возвращает число уникальных значений.
- 28. Как определить сколько раз встречается каждое значение в столбце "Город"?

df['Город'].value_counts()

- 29. Почему display(df) лучше, чем print(df), в Jupyter Notebook?
- display() показывает таблицу в более читаемом виде с форматированием, а print() выводит в виде текста, что менее удобно.
- 30. Как изменить максимальное количество строк, отображаемых в DataFrame в Jupyter Notebook?

import pandas as pd

pd.set_option('display.max_rows', 100)

Вывод: в ходе этой лабораторной работы были получены навыки с основами работы с библиотекой pandas, в частности, со структурой данных DataFrame.